

ЛЕКЦИЯ 8. БРОКЕРЫ СООБЩЕНИЙ. ТРАССИРОВКА. МЕТРИКИ. НАГРУЗОЧНОЕ ТЕСТИРОВАНИЕ.

OZON

МОСКВА, 2021

ВВОДНАЯ

Привет!

Меня зовут Ивлиев Сергей Андреевич, но можно и Сириус и ко мне лучше (конечно же) на ты ^_^

А так я:

- Делаю модерацию (и даже ML модерацию) в OZON
- кандидат технических наук
- старший преподаватель на кафедре Прикладной Математике и Искусственного Интеллекта НИУ МЭИ



ВВОДНАЯ

Меня можно найти:

- vk: <https://vk.com/siriusfreak>
- telegram: <https://t.me/siriusfreak>
- inst: <https://www.instagram.com/siriusfreak/>
- fb: <https://www.facebook.com/siriusfrkru>
- и мой сайт <https://siriusfrk.ru>
- А тут можно оставить отзыв:
<https://docs.google.com/forms/d/1bZnCdon5KON8UgSqWTv7Bv5hlnuGAnMNEC8Nta2JFt>

ТЕМЫ

Сегодня мы поговорим про:

1. Брокеры сообщений: зачем и как с этим взаимодействовать (на примере Apache Kafka).
2. Трассировка: когда логов недостаточно.
3. Метрики: биение сердца вашего сервиса.
4. Нагрузочное тестирование: как стрелять по сервису.

ЧЕМУ МЫ НАУЧИМСЯ СЕГОДНЯ?

1. Как сделать ещё один канал обмена сервиса с внешним миром.
2. Как эффективно следить за тем, как у вас работает сервис и как понять где что-то пошло не так.
3. Как попытаться убить свой сервис и какие из этого можно сделать выводы.
4. Ну а ещё сделаем docker-compose файл для всего окружения.

ЧТО ТАКОЕ ЛОГ?

А вообще что такое лог?

Лог – это структура данных, в которую можно добавлять только в конец.

Из лога можно прочесть определённое сообщение, только зная его смещение относительно начала лога.

С точки зрения потребителя – брокеры сообщений представляют возможность работы с логами, которые в их мире называются очередями сообщений.

ЧТО ТАКОЕ БРОКЕР СООБЩЕНИЙ?

В идеальном мире данные не теряются, всё надёжно, нет ни единого разрыва.

В реальном есть большое количество проблем. Каких?

1. Может пропасть сетевая связанность
2. Могут записаться битые данные
3. Сообщение может уйти не туда
4. Сообщений может стать слишком много
5. Какой-то из сервисов может внезапно умереть

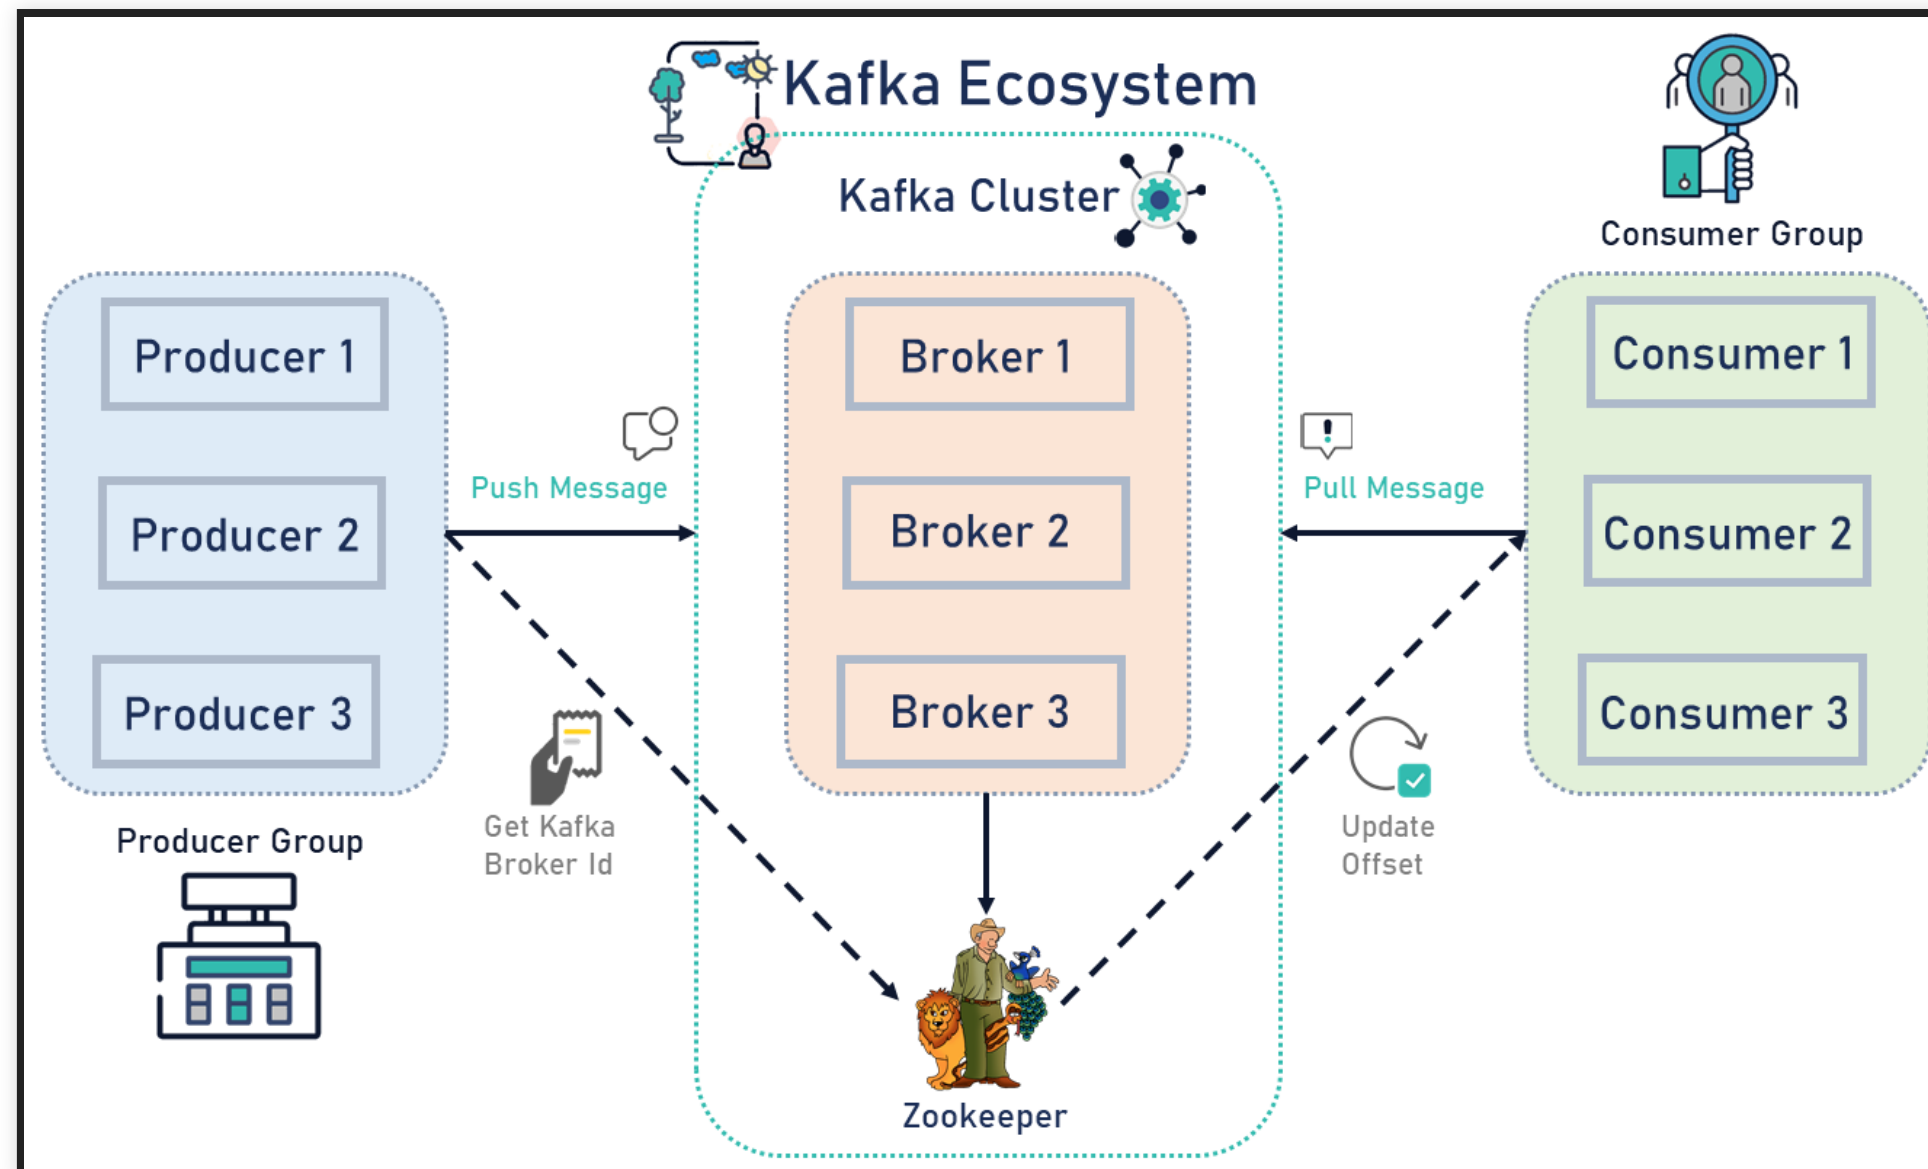
ЧТО ТАКОЕ КАФКА?

ПО, реализующее очередь сообщений:

- распределённое
- горизонтально масштабируемое
- отказоустойчивое
- долговечное (пока мы не решим очистить)

Разработано LinkedIn, отдано для развития Apache Foundation.

КАК ВЫГЛЯДИТ ОНО В ОБЩЕМ?



КАК ВЫГЛЯДИТ ОНО В ОБЩЕМ?

Для того, чтобы Kafka работала в кластере, ей требуется вспомогательный сервис Zookeeper.

Zookeeper – хранит метаданные и является координатором для нескольких экземпляров Kafka.

КАК ПОДНЯТЬ КЛАСТЕР КАФКА?

Разумеется, через docker.

```
version: "3"
services:
  zookeeper:
    image: confluentinc/cp-zookeeper
    ports:
      - "2181:2181"
    environment:
      zk_id: "1"
      ZOOKEEPER_CLIENT_PORT: 32181
      ZOOKEEPER_TICK_TIME: 2000
      ZOOKEEPER_SYNC_LIMIT: 2

  kafka:
    image: confluentinc/cp-kafka
    depends_on:
      - zookeeper
    ports:
      - "127.0.0.1:9094:9094"
    environment:
      KAFKA_ZOOKEEPER_CONNECT: "zookeeper:32181"
      KAFKA_LISTENERS: INTERNAL://kafka:9092,OUTSIDE://kafka:9094
      KAFKA_ADVERTISED_LISTENERS: INTERNAL://kafka:9092,OUTSIDE://localhost:9094
      KAFKA_LISTENER_SECURITY_PROTOCOL_MAP: INTERNAL:PLAINTEXT,OUTSIDE:PLAINTEXT
      KAFKA_INTER_BROKER_LISTENER_NAME: INTERNAL
```

Можно больше брокеров, но они все не уместились. Для подключения нужно знать адреса всех брокеров.

КАК ОНО ВСЁ ВНУТРИ?

События делятся логически на некоторые именованные топики.

У топика есть свои параметры:

1. объем хранимых данных и/или их возраст (`retention.bytes`, `retention.ms`) – то есть когда мы будем чистить топик от старых сообщений;
2. фактор избыточности данных (`replication factor`) – сколько копий сообщения у нас есть в кластере;
3. максимальный размер одного сообщения (`max.message.bytes`);
4. минимальное число согласованных реплик, при котором в топик можно будет записать данные (`min.insync.replicas`);
5. и другие;

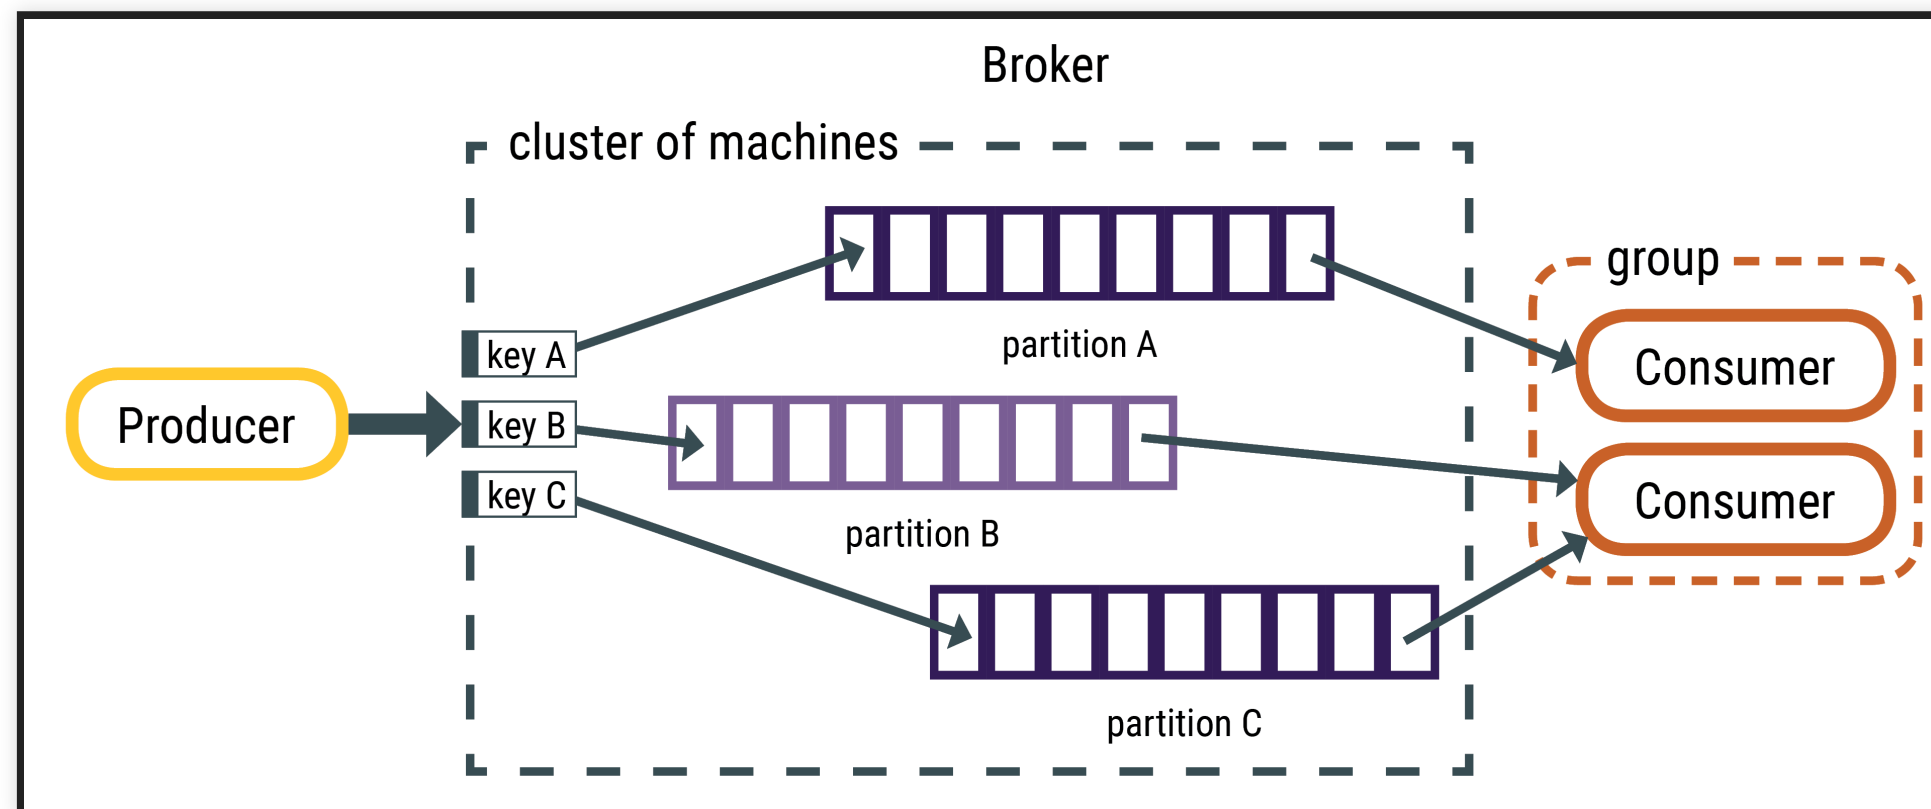
КАК ОНО ВСЁ ВНУТРИ?

В свою очередь каждый топик разбивается на одну и более партицию (partition). Именно в партиции в итоге попадают события.

Если в кластере более одного брокера, то партиции будут распределены по всем брокерам равномерно (насколько это возможно), что позволит масштабировать нагрузку на запись и чтение в один топик сразу на несколько брокеров.

В итоге механизм партиций позволяет обеспечивать масштабируемость и отказоустойчивость.

КАК ОНО ВСЁ ВНУТРИ?



ЧТО ТАКОЕ PRODUCER?

Producer отправляет события в топик. Это может быть какой-то сервис, либо даже отдельный скрипт.

Каждое такое событие представляет из себя пару ключ-значение.

Ключ может быть не задан, тогда события распределяются между патрициями по очереди и может теряться их упорядоченность.

Если ключ задан, то от него берётся хэш и события распределяются с сохранением порядка в рамках одной патриции.

ЧТО ТАКОЕ CONSUMER?

Consumer это опять же некоторый сервис, который в данном случае потребляет приходящие события. Он может быть подписан на несколько топиков.


Важным параметром для consumer является offset, который показывает как далеко мы прошли по топiku.

Offset может обновляться автоматически Kafka (`enable.auto.commit = true`) или по сообщению с консьюмера. В проде обычно используется второй вариант.

Предполагается, что offset всегда будет расти.

Consumer могут объединяться в группы. У каждой группы свой offset.

КАК ОНО ВСЁ ВНУТРИ?



КАКИЕ БИБЛИОТЕКИ НА GO ЕСТЬ ДЛЯ КАФКА?

- Sarama, которая на сегодняшний день является самой популярной, но с которой довольно трудно работать. Он плохо документирован, API предоставляет низкоуровневые концепции протокола Кафки и не поддерживает последние функции Go, такие как контексты. Также передает все значения в качестве указателей, что приводит к большому количеству динамических выделений памяти, более частым сборкам мусора и более высокому использованию памяти.

<https://github.com/Shopify/sarama>

КАКИЕ БИБЛИОТЕКИ НА GO ЕСТЬ ДЛЯ КАФКА?

- Confluent-kafka-go-это оболочка на основе cgo вокруг librdkafka, что означает, что она вводит зависимость библиотеки C от всего кода Go, использующего пакет. Он имеет гораздо лучшую документацию, чем sarama, но все еще не поддерживает контексты Go.

<https://github.com/confluentinc/confluent-kafka-go>

КАКИЕ БИБЛИОТЕКИ НА GO ЕСТЬ ДЛЯ КАФКА?

- `goka` - это более поздний клиент Kafka для Go, который фокусируется на определенном шаблоне использования. Он предоставляет абстракции для использования Кафки в качестве шины передачи сообщений между службами, а не упорядоченного журнала событий, но это не типичный случай использования Кафки для нас в сегменте. Пакет также зависит от `Sarama` для всех взаимодействий с Кафкой.

<https://github.com/lovoo/goka>

ПРИМЕР РАБОТЫ С БИБЛИОТЕКОЙ SARAMA. CONSUMER

```
package main

import (
    "fmt"

    "github.com/Shopify/sarama"
)

func subscribe(topic string, consumer sarama.Consumer) {
    partitionList, err := consumer.Partitions(topic) //get all partitions on the given topic
    if err != nil {
        fmt.Println("Error retrieving partitionList ", err)
    }
    initialOffset := sarama.OffsetOldest //get offset for the oldest message on the topic

    for _, partition := range partitionList {
        pc, _ := consumer.ConsumePartition(topic, partition, initialOffset)

        go func(pc sarama.PartitionConsumer) {
            for message := range pc.Messages() {
                messageReceived(message)
            }
        }(pc)
    }
}

func messageReceived(message *sarama.ConsumerMessage) {
    saveMessage(string(message.Value))
}
```

ПРИМЕР РАБОТЫ С БИБЛИОТЕКОЙ. PRODUCER

```
package main

import "github.com/Shopify/sarama"

var brokers = []string{"127.0.0.1:9094"}

func newProducer() (sarama.SyncProducer, error) {
    config := sarama.NewConfig()
    config.Producer.Partitioner = sarama.NewRandomPartitioner
    config.Producer.RequiredAcks = sarama.WaitForAll
    config.Producer.Return.Successes = true
    producer, err := sarama.NewSyncProducer(brokers, config)

    return producer, err
}

func prepareMessage(topic, message string) *sarama.ProducerMessage {
    msg := &sarama.ProducerMessage{
        Topic:    topic,
        Partition: -1,
        Value:    sarama.StringEncoder(message),
    }

    return msg
}
```

ПРИМЕР РАБОТЫ С БИБЛИОТЕКОЙ. MAIN.GO

```
package main

import (
    "fmt"
    "html"
    "log"
    "net/http"

    "github.com/Shopify/sarama"
)

const topic = "sample-topic"

func main() {
    producer, err := newProducer()
    if err != nil {
        fmt.Println("Could not create producer: ", err)
    }

    consumer, err := sarama.NewConsumer(brokers, nil)
    if err != nil {
        fmt.Println("Could not create consumer: ", err)
    }

    subscribe(topic, consumer)

    http.HandleFunc("/", func(w http.ResponseWriter, r *http.Request) { fmt.Fprint(w, "Hello Sarama!")
```

ПРИМЕР РАБОТЫ С БИБЛИОТЕКОЙ. MAIN.GO

```
http.HandleFunc("/save", func(w http.ResponseWriter, r *http.Request) {
    defer r.Body.Close()
    r.ParseForm()
    msg := prepareMessage(topic, r.FormValue("q"))
    partition, offset, err := producer.SendMessage(msg)
    if err != nil {
        fmt.Fprintf(w, "%s error occurred.", err.Error())
    } else {
        fmt.Fprintf(w, "Message was saved to partion: %d.\nMessage offset is: %d.\n", partition, c
    }
})

http.HandleFunc("/retrieve", func(w http.ResponseWriter, r *http.Request) { fmt.Fprint(w, html.Esc
log.Fatal(http.ListenAndServe(":8081", nil))
}
```


БОЛЬШЕ ПРО КАФКА

1. Apache Kafka: Что это и как она изменит архитектуру вашего приложения
<https://www.youtube.com/watch?v=nkYW7YqJYmE>
2. Apache Kafka, открытый базовый курс: <https://www.youtube.com/playlist?list=PL8D2P0ruohOAR7DAkEjhOqlQreg9rxBMu>

ЧТО ТАКОЕ МЕТРИКИ?

Метрики – это некоторые показатели, которые сообщает ваш сервис в режиме реального времени. Они показывают насколько сервис здоровый, как эффективно он обрабатывает сообщения.

Метрики пишутся в определённое хранилище, которое хранит их значения относительно времени. Это ещё один вид БД, который оперирует именно временными последовательностями.

КАКИЕ БЫВАЮТ ТИПЫ МЕТРИК?

- счётчик (counter) — хранит значения, которые увеличиваются с течением времени (например, количество запросов к серверу);
- шкала (gauge) — хранит значения, которые с течением времени могут как увеличиваться, так и уменьшаться (например, объём используемой оперативной памяти или количество операций ввода-вывода);
- гистограмма (histogram) — хранит информацию об изменении некоторого параметра в течение определённого промежутка (например, общее количество запросов к серверу в период с 11 до 12 часов и количество запросов к этому же серверов в период с 11.30 до 11.40);
- сводка результатов (summary) — как и гистограмма, хранит информацию об изменении значения некоторого параметра за временной интервал, но также позволяет рассчитывать квантили для скользящих временных интервалов.

ЧТО ТАКОЕ МЕТРИКИ?

У значений метрик могут проставляться разные метки (labels). Пример метрики:

`http_response_code` – её значение – количество . Она имеет тип `counter`.

Её метки: `browser`, `response_code`, `time_grade`, `handle`.

Выборки можно проводить относительно каждой метки. То есть можно выбрать количество запросов, которые вернули 404 или количество запросов к определённой ручке, которые выполнялись за определённое время.

ЧТО ТАКОЕ МЕТРИКИ?

Метки должны иметь малое (не более 30) количество разных значений. К примеру для time_grade:

- 0-100ms
- 100-200ms
- 200-500ms
- 500-100ms
- 1s-5s
- 5s-10s
- И т.д.

ЧТО ТАКОЕ МЕТРИКИ?

При проектировании метрик надо помнить, что метрики собираются пока сервис работает. Как сервис умирает или по какой-то другой причине прекращает транслировать метрику – могут быть сайд-эффекты.

К примеру:

PROMETHEUS

Prometheus – система, объединяющая мониторинг и сбор данных, а также систему для хранения метрик.

Это внешний сервис, который собирает метрики от сервисов и агрегирует их внутри себя.

Он имеет свой встроенный язык запросов PromQL.

PROMQL

```
>> node_load1  
node_load1{instance="localhost:9100",job="node"} = 0.96  
node_load1{instance="anotherhost:9100",job="node"} = 0.44
```

- node_load1 — имя метрики,
- instance и job — имена меток,
- localhost:9100 и node — соответствующие значения меток
- 0.96 — значение метрики.

```
>> node_load1{instance!='localhost:9100'}  
node_load1{instance="anotherhost:9100",job="node"} = 0.96
```


PROMQL

```
>> node_filesystem_avail_bytes
node_filesystem_avail_bytes{device="/dev/nvme0n1p1",fstype="vfat",instance="localhost:9100",
job="node",mountpoint="/boot"} = 143187968
node_filesystem_avail_bytes{device="/dev/nvme0n1p2",fstype="ext4",instance="localhost:9100",
job="node",mountpoint="/" } = 340473708544
node_filesystem_avail_bytes{device="/dev/sda1",fstype="ext4",instance="anotherhost:9100",
job="node",mountpoint="/" } = 429984710656
node_filesystem_avail_bytes{device="run",fstype="tmpfs",instance="localhost:9100",
job="node",mountpoint="/run"} = 4120506368
node_filesystem_avail_bytes{device="tmpfs",fstype="tmpfs",instance="localhost:9100",
job="node",mountpoint="/tmp"} = 4109291520
node_filesystem_avail_bytes{device="tmpfs",fstype="tmpfs",instance="anotherhost:9100",
job="node",mountpoint="/run"} = 104542208
```

PROMQL

```
>> node_filesystem_avail_bytes / node_filesystem_size_bytes * 100
{device="/dev/nvme0n1p1",fstype="vfat",instance="localhost:9100",job="node",mountpoint="/boot"} = 54.1
{device="/dev/nvme0n1p2",fstype="ext4",instance="localhost:9100",job="node",mountpoint="/"} = 73.94176
{device="/dev/sda1",fstype="ext4",instance="anotherhost:9100",job="node",mountpoint="/"} = 68.54660550
{device="run",fstype="tmpfs",instance="localhost:9100",job="node",mountpoint="/run"} = 99.968001748972
{device="tmpfs",fstype="tmpfs",instance="localhost:9100",job="node",mountpoint="/tmp"} = 99.6959172417
{device="tmpfs",fstype="tmpfs",instance="anotherhost:9100",job="node",mountpoint="/run"} = 9
```

PROMQL

```
>> node_cpu_seconds_total  
  
27687.16node_cpu_seconds_total{cpu="0",instance="localhost:9100",job="node",mode="idle"} = 349.98  
node_cpu_seconds_total{cpu="0",instance="localhost:9100",job="node",mode="iowait"} = 0  
node_cpu_seconds_total{cpu="0",instance="localhost:9100",job="node",mode="irq"} = 4.5  
node_cpu_seconds_total{cpu="0",instance="localhost:9100",job="node",mode="nice"} = 342.47  
node_cpu_seconds_total{cpu="0",instance="localhost:9100",job="node",mode="softirq"} = 0  
node_cpu_seconds_total{cpu="0",instance="localhost:9100",job="node",mode="steal"} = 734.43  
node_cpu_seconds_total{cpu="0",instance="localhost:9100",job="node",mode="system"} = 2386.23  
node_cpu_seconds_total{cpu="0",instance="localhost:9100",job="node",mode="user"} = 27613.56  
node_cpu_seconds_total{cpu="1",instance="localhost:9100",job="node",mode="idle"} = 328.26
```

PROMQL

```
>> max by (instance) (node_cpu_seconds_total)
{instance="localhost:9100"} = 18309.45
{instance="anotherhost:9100"} = 3655352.98

>> max by (instance, cpu) (node_cpu_seconds_total)
{cpu="3",instance="localhost:9100"} = 17623.34
{cpu="0",instance="localhost:9100"} = 18295.97
{cpu="0",instance="anotherhost:9100"} = 3529407.76
{cpu="1",instance="localhost:9100"} = 18252.21
{cpu="1",instance="anotherhost:9100"} = 3655379.15
{cpu="2",instance="localhost:9100"} = 18334

>> max without (mode) (node_cpu_seconds_total)
{cpu="1",instance="anotherhost:9100",job="node"} = 3655736.46
{cpu="2",instance="localhost:9100",job="node"} = 18752.74
{cpu="3",instance="localhost:9100",job="node"} = 18022.19
{cpu="0",instance="localhost:9100",job="node"} = 18716.18
{cpu="0",instance="anotherhost:9100",job="node"} = 3529779.38
{cpu="1",instance="localhost:9100",job="node"} = 18670.74
```

СОБИРАЕМ ВСЁ ВМЕСТЕ

Нам потребуется конфигурационный файл `prometheus.yml`.

```
global:
  scrape_interval: 10s

scrape_configs:
  - job_name: 'node'
    static_configs:
      - targets: ['192.168.100.17:9100']
```

- 192.168.100.17 – IP адрес компьютера, где запущен наш сервис, чтобы к нему можно было достучаться из докера
- 9100 – порт сервиса, который будет возвращать значения метрик

DOCKER-COMPOSE

```
version: "3"
services:
  prometheus:
    image: prom/prometheus
    ports:
      - "9090:9090"
    volumes:
      - "./prometheus.yml:/etc/prometheus/prometheus.yml"
```

ИСПОЛЬЗОВАНИЕ ИЗ GO

```
package main

import (
    "net/http"
    "github.com/prometheus/client_golang/prometheus/promhttp"
)

func main() {
    http.Handle("/metrics", promhttp.Handler())
    // ...
    println("listening..")
    http.ListenAndServe(":9100", nil)
}
```

ИСПОЛЬЗОВАНИЕ ИЗ GO


```
// create a new counter vector
var getBookCounter = prometheus.NewCounterVec(
    prometheus.CounterOpts{
        Name: "http_request_get_books_count", // metric name
        Help: "Number of get_books request.",
    },
    []string{"status"}, // labels
)

func init() {
    // must register counter on init
    prometheus.MustRegister(getBookCounter)
}
```

ИСПОЛЬЗОВАНИЕ ИЗ GO

```
func bookHandler(w http.ResponseWriter, r *http.Request) {
    var status string
    defer func() {
        // increment the counter on defer func
        getBookCounter.WithLabelValues(status).Inc()
    }()

    books, err := getBooks(r.FormValue("category"))
    if err != nil {
        status = "error"
        w.Write([]byte("something's wrong: " + err.Error()))
        return
    }

    resp, err := json.Marshal(books)
    if err != nil {
        status = "error"
        w.Write([]byte("something's wrong: " + err.Error()))
        return
    }

    status = "success"
    w.Write(resp)
}
```

OPENTRACING И JAEGER

Трейс позволяет понять к каким другим сервисам, БД и прочему обращался микросервис.

Трейс может проходить через несколько сервисов, каждый из которых будет обогащать его своими данными.

В трейс можно записать логи и ключи, по которым можно найти нужные трейсы.

Opentracing – это свободное API для сбора трейсов.

<https://github.com/opentracing/opentracing-go>

Jaeger – это Opentracing-совместимый сборщик трейсов.

<https://github.com/jaegertracing/jaeger-client-go>

ПОДКЛЮЧЕНИЕ К ПРОЕКТУ

```
import (
    "log"
    "os"

    opentracing "github.com/opentracing/opentracing-go"
    "github.com/uber/jaeger-lib/metrics"

    "github.com/uber/jaeger-client-go"
    jaegercfg "github.com/uber/jaeger-client-go/config"
    jaegerlog "github.com/uber/jaeger-client-go/log"
)
...
func main() {
    // Sample configuration for testing. Use constant sampling to sample every trace
    // and enable LogSpan to log every span via configured Logger.
    cfg := jaegercfg.Configuration{
        ServiceName: "your_service_name",
        Sampler:      &jaegercfg.SamplerConfig{
            Type: jaeger.SamplerTypeConst,
            Param: 1,
        },
        Reporter:      &jaegercfg.ReporterConfig{
            LogSpans: true,
        },
    }

    // Example logger and metrics factory. Use github.com/uber/jaeger-client-go/log
    // and github.com/uber/jaeger-lib/metrics respectively to bind to real logging and metrics
    // frameworks.
```

ЗАПУСК ТРЕЙСА

```
import (  
    opentracing "github.com/opentracing/opentracing-go"  
)  
...  
tracer := opentracing.GlobalTracer()  
span := tracer.StartSpan("say-hello")  
println(helloStr)  
span.Finish()
```

СОЗДАНИЕ ПОДТРЕЙСА

```
import (
    opentracing "github.com/opentracing/opentracing-go"
)
...
tracer := opentracing.GlobalTracer()
parentSpan := tracer.StartSpan("parent")
defer parentSpan.Finish()
...
// Create a Child Span. Note that we're using the ChildOf option.
childSpan := tracer.StartSpan(
    "child",
    opentracing.ChildOf(parentSpan.Context()),
)
defer childSpan.Finish()
```

ВСТРАИВАНИЕ В CONTEXT. КЛИЕНТ.

```
import (
    "net/http"

    opentracing "github.com/opentracing/opentracing-go"
    "github.com/opentracing/opentracing-go/ext"
)
...
tracer := opentracing.GlobalTracer()

clientSpan := tracer.StartSpan("client")
defer clientSpan.Finish()

url := "http://localhost:8082/publish"
req, _ := http.NewRequest("GET", url, nil)

// Set some tags on the clientSpan to annotate that it's the client span. The additional HTTP tags are
ext.SpanKindRPCClient.Set(clientSpan)
ext.HTTPUrl.Set(clientSpan, url)
ext.HTTPMethod.Set(clientSpan, "GET")

// Inject the client span context into the headers
tracer.Inject(clientSpan.Context(), opentracing.HTTPHeaders, opentracing.HTTPHeadersCarrier(req.Header))
resp, _ := http.DefaultClient.Do(req)
```

ВСТРАИВАНИЕ В CONTEXT. СЕРВЕР.

```
import (
    "log"
    "net/http"

    opentracing "github.com/opentracing/opentracing-go"
    "github.com/opentracing/opentracing-go/ext"
)

func main() {
    // Tracer initialization, etc.

    ...

    http.HandleFunc("/publish", func(w http.ResponseWriter, r *http.Request) {
        // Extract the context from the headers
        spanCtx, _ := tracer.Extract(opentracing.HTTPHeaders, opentracing.HTTPHeadersCarrier(r.Header))
        serverSpan := tracer.StartSpan("server", ext.RPCServerOption(spanCtx))
        defer serverSpan.Finish()
    })

    log.Fatal(http.ListenAndServe(":8082", nil))
}
```


НАГРУЗОЧНОЕ ТЕСТИРОВАНИЕ

Нагрузочное тестирование (англ. load testing) — подвид тестирования производительности, сбор показателей и определение производительности и времени отклика программно-технической системы или устройства в ответ на внешний запрос с целью установления соответствия требованиям, предъявляемым к данной системе (устройству).

Оно позволяет понять какие вообще есть возможности есть у нашего сервиса, его узкие места.

- Танк – сервис, который стреляет из пушки снарядом и собирает статистику о выстреле.
- Пушка – скрипт или программа, которая генерирует нагрузку на сервис.
- Снаряд – собственно нагрузка на сервис (отдельный запрос или сценарий).

НАПИСАНИЕ ПУШКИ

В качестве пушки мы будем использовать Yandex.Pandora.

Этот фреймворк позволяет делать кастомные пунки на Go, которые обладают высокой производительностью и позволяют обстреливать сервис.

Пример такой пушки:

https://github.com/yandex/pandora/blob/develop/examples/custom_pandora/custom_mai

ПРОВЕДЕНИЕ СТРЕЛЬБ

Для проведения стрельб требуется конфиг определённого формата:

```
pools:
- gun:
  type: my-custom-gun-name
  target: example.com:80

  ammo:
    type: my-custom-provider-name
    source: # You may just write file path here. Or stdin.
    type: inline
    data: |
      {"url": "url1", "queryParams": "query1"}
      {"url": "url2", "queryParams": "query2"}
  result:
    type: json
    sink: stdout # Just for interactivity print result to stdout. Usually file used here.

rps:
- {duration: 2s, type: line, from: 1, to: 5}
- {duration: 3s, type: const, ops: 5}
- {duration: 2s, type: line, from: 5, to: 1}

startup:
  type: once
  times: 5

log:
  level: debug
```

ПРОВЕДЕНИЕ СТРЕЛЬБ

Для запуска надо указать файл:

```
pandora myconfig.yaml
```

Логи можно визуализировать через Yandex.Tank, либо посмотреть метрики сервиса в графанах.